

') repeat;">>



# Prédiction des Tarifs de Taxi NYC



Présentation Projet ML



Modèle de Régression Supervisée pour  
la Prédiction du Montant des Courses



2018

Yacine Frikich - Rezala Ayoub

Janvier 2025



') repeat;">>

# Contexte Business & Enjeux

## Opportunités du Marché

### Objectif

Prédire fare\_amount avec des algorithmes de régression supervisée




### Source de Données

NYC Taxi & Limousine Commission 2018  
8 000 000+ courses, 17 variables



### Impact Business

- Estimation coût avant départ
- Optimisation revenus chauffeur
- Efficacité allocation flotte



Estimation Coût



Optimisation



Gestion de Flotte

**8M+**

Courses de Taxi

**17**

Variables

**2018**

Année Dataset

') repeat;">>

# Problématique & Impact Business

Bénéfices pour les Parties Prenantes



## Clients

Tarification transparente

Estimation coût avant trajet



## Chauffeurs

Optimisation revenus

Meilleure planification itinéraires



## Gestionnaires Flotte

Tarification dynamique

Optimisation allocation ressources



## Défi

Prédiction précise des tarifs dans un environnement urbain complexe avec des modèles de trafic dynamiques, une demande variable et multiples facteurs de tarification



') repeat;">>

# Aperçu du Dataset

## Fondation des Données



### Source des Données

NYC Taxi & Limousine Commission  
Données officielles de transport  
gouvernemental

**8M+**

Trajets Total

**2018**

Année Dataset

**100K**

Échantillon

## Pipeline de Données

Données  
Brutes



### Nettoyage



### Variables



### Entraînement



## Variables Clés (17 Caractéristiques)



### Variable Cible

fare\_amount  
Tarif taxi en USD



### Trajet

trip\_distance, coordonnées  
prise/dépose, datetime



### Financier

tip\_amount, tolls\_amount,  
payment\_type, frais extra



## Considérations Qualité des Données

Nécessite préprocessing pour valeurs aberrantes, valeurs manquantes et coordonnées invalides. Réduction échantillon de 8M à 100K records pour entraînement efficace.



### Valeurs Aberrantes

Tarifs négatifs, distances extrêmes



### Valeurs Manquantes

Enregistrements incomplets





### Échantillon Propre

100K enregistrements traités

') repeat;">>

# Analyse Exploratoire des Données

## Statistiques Clés



Résumé Statistique des Variables Clés			
Montant Tarif (\$)	Distance (km)	Pourboire (\$)	Détection Aberrants
Min : 2,50 \$ Q1 : 5,50 \$ Max : 200,00 \$ Q3 : 15,00 \$ Médiane : 8,50 \$ IQR : 9,50 \$	Min : 0,2 Q1 : 1,4 Max : 40,0 Q3 : 5,1 Médiane : 2,9 IQR : 3,7	Min : 0,00 \$ Q1 : 0,00 \$ Max : 50,00 \$ Q3 : 2,45 \$ Médiane : 1,35 \$ IQR : 2,45 \$	1,5% valeurs extrêmes Supprimés pour entraînement Z-score > 3,0



') repeat;">

# Corrélations & Insights Clés

## Relations entre Variables

### Matrice de Corrélation

	prix_course	distance_trajet	duree_trajet	peages
prix_course	1,00	0,94	0,82	0,32
distance_trajet	0,94	1,00	0,78	0,28
duree_trajet	0,82	0,78	1,00	0,15
peages	0,32	0,28	0,15	1,00

Fort: 0,8+ | Modéré: 0,5-0,8 | Faible: <0,5

### Principales Corrélations avec le Prix

	<b>Distance du Trajet</b> Corrélation positive forte	<b>0,94</b>
	<b>Durée du Trajet</b> Corrélation positive modérée	<b>0,82</b>
	<b>Montant des Péages</b> Corrélation positive faible	<b>0,32</b>

### Classement d'Importance des Variables

1	distance_trajet	94%
2	duree_trajet	82%
3	lieu_depart	58%
4	heure_journee	43%

### Insights Business

- La distance est le prédicteur le plus fort - les modèles de tarification doivent fortement pondérer la distance.
- Les facteurs temporels comptent - heures de pointe et conditions de trafic impactent les tarifs.
- Opportunités de tarification géographique - certaines zones de départ commandent des tarifs premium.
- Les péages ont un impact minimal sur le tarif de base - structure de frais séparée recommandée.



### Points Clés pour le Modèle ML

Concentrer sur les variables distance et durée pour des prédictions précises. Les fortes corrélations permettent une estimation fiable avec des modèles linéaires simples. Variables géographiques et temporelles apportent un pouvoir prédictif additionnel.

) repeat;">

# Pipeline ML & Préparation des Données

## Méthodologie



### Étapes de Traitement

#### Échantillonnage

Échantillonnage aléatoire stratifié de 100 000 enregistrements sur 8M+ pour assurer une distribution représentative.

#### Nettoyage

Suppression des valeurs aberrantes par méthode IQR. Imputation des valeurs manquantes avec médiane/mode selon le type.

#### Prétraitement

Normalisation des variables numériques. Encodage one-hot pour les variables catégorielles. Variables temporelles et géographiques.

#### Division

80% entraînement (80k), 20% test (20k). Division stratifiée maintenant la distribution cible.

### Variables Sélectionnées

#### distance\_trajet

Prédicteur principal  
Distance en miles

#### type\_paiement

Espèces/Carte/etc  
Méthode de paiement

#### taxe\_mta

Taxe MTA fixe  
\$0.50 standard

#### code\_tarif

Structure tarifaire  
Standard/JFK/Newark

#### suppléments

Frais additionnels  
Heures de pointe

#### montant\_pourboire

Pourboire client  
Variable/Cible

### Visualisation de la Division Train/Test

80%

Jeu d'Entraînement  
80 000 observations

Jeu de Test  
20 000 observations



Modèle Prêt

Données prétraitées

') repeat;">>

# Modèle de Régression Linéaire

## Algorithme & Équation


### Équation du Modèle

$$\text{tarif} = 4,12 + 2,65 \times \text{distance} + 0,85 \times \text{code\_tarif} + 0,42 \times \text{pourboire} + 1,05 \times \text{extra} + 2,10 \times \text{taxe\_mta}$$

#### Interprétation des Coefficients

<b>4,12</b>	<b>Tarif de Base</b>	Tarif de départ pour tout trajet
<b>2,65</b>	<b>Distance</b>	$(4,12\$)$ 2,65\$ par mile parcouru
<b>0,85</b>	<b>Code Tarif</b>	Multiplicateur de structure
<b>0,42</b>	<b>Pourboire</b>	$\text{tarifaire}$ Impact de la gratification client
<b>1,05</b>	<b>Frais Extra</b>	Frais heures de pointe/nuit

#### Magnitude des Coefficients



#### Hypothèses du Modèle

- ✓ Relation linéaire entre variables et cible
- ✓ Indépendance des observations
- ✓ Variance constante des résidus
- ✓ (homoscédasticité)  
Distribution normale des résidus

#### Approche de Validation

- ↻ **Validation Croisée**  
Répétition pour stabilité modèle
- ↳ **Analyse Résiduelle**  
Vérification Q-Q, résidus vs ajustés
- ⌚ **Métriques**  
Évaluation R<sup>2</sup>, RMSE, MAE

Apprentissage Supervisé

Régression Linéaire

Multi-variables


Interprétable

) repeat;">


# Performance du Modèle

## Résultats & Interprétation


### Tableau de Bord des Métriques



### Valeurs Réelles vs Prédites



### Distribution des Erreurs



### Impact Business & Interprétation



#### Haute Précision

92% de variance expliquée avec erreur de prédiction moyenne de seulement 2,10\$



#### Déploiement Production

Fiabilité du modèle suffisante pour système de prédiction tarifaire réel



#### Valeur Business

Estimations tarifaires précises améliorent satisfaction client et optimisation revenus

**Haute Performance**

**Modèle Fiable**

**Faible Taux d'Erreur**


**Validé**

') repeat;">>

# Stratégie de Surveillance et KPI

## Supervision de Production

### Métriques de Performance en Temps Réel




### Détection de Dérive des Données



### État de Dérive des Variables

distance	Stable
tarif_type	Alerte
pourboire	Stable

### Surveillance Performance du Modèle




Tendance Performance 7 Derniers Jours

### État Détection de Dérive

**Dérive Concept**  
Précision du modèle en baisse due aux changements

**Dérive Prédiction**  
Distributions de sortie dans les plages attendues

### Système d'Alertes et Réponses Automatisées



Grafana

Elasticsearch


PagerDuty

Slack

# Déploiement Azure & Structure des Coûts

Architecture Cloud & Coûts

## Architecture Azure de Production



## Répartition Coûts Mensuels

### Scénario Léger (~49€/mois)

Container Instances <b>2€</b> 1 vCPU, 2GB RAM	Blob Storage <b>12€</b> 100GB stockage	App Insights <b>7€</b> Suivi basique	Azure ML <b>5€</b> Niveau base
-----------------------------------------------------	----------------------------------------------	--------------------------------------------	--------------------------------------

### Scénario Moyen (~180€/mois)

Cluster AKS <b>120€</b> Cluster 3 nœuds	Blob Storage <b>25€</b> 500GB stockage	App Insights <b>20€</b> Logs enrichis	Azure ML <b>15€</b> Niveau standard
-----------------------------------------------	----------------------------------------------	---------------------------------------------	-------------------------------------------

## Stratégie de Montée en Charge & Optimisation



## Stratégies d'Optimisation des Coûts

**Auto-scaling**  
Réduction automatique pendant faible usage. Azure Functions pour charges sporadiques

**Instances Réservées**  
Économisez jusqu'à 72% avec engagements 1-3 ans pour charges prévisibles

## Infrastructure Prête pour la Production



### Sécurité & Conformité

- Gestion des secrets
- Réseaux virtuels (VNet)
- Points de terminaison privés
- Contrôle d'accès basé sur les rôles
- Chiffrement données au repos



**Rentable**



### Haute Disponibilité

- Réplication dans plusieurs régions
- Équilibrage de charge
- Basculement automatique
- Vérifications état
- SLA cible 99,9%



**Auto-Scalable**



### DevOps & CI/CD

- Pipelines Azure DevOps
- Tests automatisés
- Déploiements bleu-vert
- Infrastructure as Code
- Workflows GitOps



### Surveillance & Alertes

- Visualisation de bord temps réel
- Métriques personnalisées
- Alertes proactives
- Agrégation logs
- Analytics performance




**Entreprise Ready**

) repeat;">>


# Prochaines Étapes & Améliorations

## Feuille de Route Future

### Matrice de Priorité des Améliorations



### Timeline de la Feuille de Route 6 Mois



### Actions Détaillées & Indicateurs de Progression

#### Améliorations Modèle

- Ajouter Variables Temporelles**
- Motifs heure/jour de la semaine
  - Indicateurs heures de pointe
  - Ajustements saisonniers

25%

#### Amélioration Algorithmes

- Tester Random Forest**
- Comparaison avec Régression Linéaire
  - Analyse importance variables
  - Benchmark performance

75%

#### Stratégie Données

- Intégrer Données Récentes**
- Registres taxis 2023-2024
  - Structures tarifaires mises à jour
  - Motifs post-pandémie

20%

- Calcul Distance GPS**
- Implémentation formule Haversine
  - Métriques efficacité trajet
  - Analyse motifs trafic

10%

- Modèles Gradient Boosting**
- Implémentation XGBoost
  - Optimisation hyperparamètres
  - Prévention surapprentissage

40%

- Variables par Zones**
- Tarification spécifique arrondissement
  - Majorations aéroport/monuments
  - Indicateurs quartiers d'affaires

0%

- Validation Croisée K-fold**
- Configuration validation 5-fold
  - Évaluation stabilité modèle
  - Analyses biais variance

90%

- Développer Ingénierie Variables**
- Intégration données météo
  - Ajustements événements
  - Facteurs tarification dynamique

15%

- Automatisation Pipeline Données**
- Ingestion données automatisée
  - Calcul variables temps réel
  - Surveillance qualité

5%

R<sup>2</sup> > 0,92

< 100ms Réponse

RMSE < 3,00\$

95% Disponibilité